

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ



دانشکده مهندسی کامپیوتر

تشخیص رتینوپاتی نوزادان زودرس (ROP) با استفاده از پردازش تصویر و یادگیری ماشین

رها یزدی

استاد راهنما:

دکتر نادر کریمی

مهر ماه ۱۴۰۴

فهرست مطالب

۱- مقدمه	۱
۱-۱- بیماری رتینوپاتی نوزادان زودرس ROP	۱
۲-۱- ضرورت تشخیص زودهنگام	۱
۲- پژوهش های پیشین	۳
۲-۱- مقدمه	۳
۲-۲- بررسی پژوهش های پیشین	۴
۳-۲- جمع بندی پژوهش های پیشین	۵
۳- تعاریف	۸
۳-۱- مدل های یاد گیری عمیق مورد استفاده	۸
ResNet۵۰	۸
EfficientNetB۰	۹
MobileNetV۲	۹
DenseNet۲۱	۹
InceptionV۳	۱۰
VGG۱۶	۱۰
۲-۳- معیارهای ارزیابی عملکرد مدل ها	۱۱
۳-۲-۱- دقت (Accuracy)	۱۲
۳-۲-۲- صحت (Precision)	۱۲
۳-۲-۳- بازیابی (Recall)	۱۲
۳-۲-۴- امتیاز F۱ (F۱-Score)	۱۳

۳-۲-۵.	مساحت زیر منحنی ROC	۱۳
-۴	کارهای انجام شده و روش پیشنهادی	۱۴
۴-۱-	مقدمه	۱۴
-۲-۴	روند کلی	۱۴
-۳-۴	پایگاه داده پژوهش	۱۵
-۴-۴	تشخیص خودکار بیماری ROP با بهره‌گیری از شبکه‌های عصبی یادگیری عمیق	
	پیش‌آموزش دیده	۱۹
-۵-۴	تشخیص ROP با بهره‌گیری از استخراج ویژگی و مدل‌های یادگیری ماشین	۲۰
۴-۵-۱	روش پیاده‌سازی و مراحل	۲۰
۴-۶-	تحلیل اثر افزایش نمونه از هر بیمار در عملکرد مدل‌های ترکیبی استفاده شده	۲۴
-۷-۴	تحلیل اثر به‌کارگیری پیش‌پردازش تصاویر در بهبود عملکرد مدل‌های استفاده شده	۲۷
۴-۷-۱	مراحل پیش‌پردازش	۲۷
	برش دایره‌ای و فیلتر گوسی	۲۷
	تنظیم روشنایی	۲۷
	افزایش کنتراست	۲۸
-۵	نتایج	۳۱
۵-۱-	مقدمه	۳۱
۵-۲-	تحلیل مرحله اول: مدل‌های یادگیری مستقیم از تصویر	۳۲

تحلیل مرحله دوم: استخراج ویژگی و	۵-۳-
۳۲	طبقه‌بندهای کلاسیک
تحلیل مرحله سوم: استفاده از چند تصویر به‌ازای	۵-۴-
۳۳	هر بیمار
تحلیل مرحله چهارم: تأثیر پیش‌پردازش	۵-۵-
۳۴	تصاویر بر عملکرد مدل‌ها
تحلیل زمان اجرا و هزینه محاسباتی مدل‌ها ۳۵	۵-۶-
۳۸..... نتیجه‌گیری	۵-۷-
۳۹..... منابع	

۱- مقدمه

۱-۱- بیماری رتینوپاتی نوزادان زودرس ROP

رتینوپاتی نوزادان زودرس یا ROP^۱ یک بیماری عروقی تکاملی شبکیه است که در نوزادانی که قبل از تکامل کامل شبکیه متولد می‌شوند، بروز می‌کند. این بیماری به دلیل توقف یا اختلال در روند طبیعی رشد عروق خونی شبکیه و رشد غیرطبیعی و تهاجمی رگ‌ها شکل می‌گیرد و در صورت عدم تشخیص و درمان به موقع، می‌تواند به خونریزی شبکیه، جداشدگی شبکیه و نهایتاً نابینایی منجر شود.

امروزه ROP یکی از دلایل اصلی نابینایی قابل پیشگیری در کودکان به شمار می‌رود. آمارهای جهانی نشان می‌دهد که بین ۶ تا ۲۰ درصد از نوزادان زودرس درجاتی از ROP را تجربه می‌کنند و این میزان در کشورهایی با نرخ بالای زایمان زودرس بیشتر است. به طور خاص، شیوع ROP در کشورهای توسعه‌یافته بین ۵ تا ۱۵ درصد گزارش شده و در کشورهای در حال توسعه می‌تواند تا ۲۰ درصد یا بیشتر نیز برسد [1].

۱-۲- ضرورت تشخیص زودهنگام

سالانه حدود ۳۲۰۳۰۰ نوزاد در سراسر دنیا به درجاتی از آسیب بینایی غیرقابل برگشت ناشی از ROP مبتلا می‌شوند که از این میان، تقریباً ۲۰۰۰۰۰ مورد منجر به نابینایی کامل یا نقص بینایی شدید می‌گردد. با افزایش نرخ بقای نوزادان نارس، شیوع جهانی ROP نیز رو به افزایش است. این مسئله لزوم تشخیص زودهنگام و غربالگری منظم را دوچندان می‌سازد [2].

¹ Retinopathy Of Prematurity

بیماری ROP شامل مراحل مختلفی است. که مراحل اولیه آن (مرحله یک و دو) در بسیاری از موارد به صورت خودبه خود بهبود می یابد، اما اگر بیماری به مراحل پیشرفته تر وارد شود، خطر نابینایی دائمی به شدت افزایش می یابد. در مراحل شدیدتر (مرحله ۳ و بالاتر یا وجود فرم پلاس) مداخلات درمانی ضرورت پیدا می کند [2].

با توجه به دلایل ذکر شده، زمان در تشخیص ROP حیاتی است. هرگونه تأخیر در شناسایی می تواند باعث از دست رفتن فرصت درمان و آسیب غیرقابل جبران به بینایی نوزاد شود. از سوی دیگر، فرایند معاینه چشم نوزادان زودرس نیازمند تجهیزات خاص، تخصص بالینی ویژه و صرف زمان زیاد است و در بسیاری از مناطق، دسترسی به متخصصان شبکه کودکان بسیار محدود است. همین موضوع باعث شده است که توسعه روش های کمکی و خودکار برای غربالگری اولیه اهمیت روزافزونی پیدا کند.

نقش پردازش تصویر و یادگیری ماشین

در سال های اخیر، پیشرفت های چشمگیر در حوزه های پردازش تصویر و یادگیری ماشین، مسیر تازه ای را برای تشخیص خودکار انواع بیماری ها هموار کرده است. پژوهش های بسیاری در سال های اخیر در تلاش برای توسعه سیستم هایی از این دست بوده اند.

تشخیص بیمار رتینوپاتی نوزادان به وسیله عکس برداری از شبکه چشم نوزاد امکان پذیر است. ای تصاویر که توسط دستگاه های تخصصی مانند RetCam و ICON تهیه می شوند، حاوی اطلاعات ارزشمندی درباره وضعیت رشد عروق هستند. در روش های متداول و سنتی پزشک با بررسی عکس ها و وضعیت عروق خونی شبکه درباره ابتلای نوزاد به بیماری اظهار نظر می کند، اما تحلیل دستی این تصاویر توسط متخصصان، هرچند دقیق، فرایندی زمان بر و مستعد خطای انسانی است.

روش های مبتنی بر یادگیری ماشین قادرند با استفاده از مجموعه داده های تصویری بزرگ، الگوهای بصری مرتبط با بیماری را شناسایی کرده و دسته بندی خودکار انجام دهند. در این میان، شبکه های عصبی کانولوشنی و مدل های یادگیری عمیق از پیش آموزش دیده توانسته اند نتایج قابل توجهی در زمینه استخراج ویژگی های معنادار از تصاویر پزشکی به دست آورند. ترکیب این مدل ها با طبقه بندی های کلاسیک^۱ می تواند دقت و سرعت تشخیص را به طور چشمگیری افزایش دهد.

¹ Classic Classifiers

چنین سیستم‌هایی علاوه بر کمک به متخصصان در تصمیم‌گیری نهایی، می‌توانند در مناطق محروم که دسترسی به چشم‌پزشک محدود است، به‌عنوان ابزار غربالگری اولیه به کار گرفته شوند و از تأخیر در تشخیص جلوگیری کنند.

۲- پژوهش های پیشین

۲-۱- مقدمه

در سال های اخیر، با رشد چشمگیر فناوری های مرتبط با یادگیری ماشین و پردازش تصویر، زمینه ای مناسب برای به کارگیری این روش ها در حوزه پزشکی و به ویژه در تشخیص بیماری های چشمی با استفاده از تصاویر شبکه فراهم شده است. یکی از بیماری هایی که توجه ویژه ای از سوی محققان به خود جلب کرده، رتینوپاتی نوزادان زودرس (ROP) است؛ اختلالی که در صورت عدم تشخیص و درمان به موقع می تواند به آسیب های جدی و حتی نابینایی منجر شود.

فرایند سنتی غربالگری و تشخیص ROP، متکی به بررسی مستقیم تصاویر شبکه توسط متخصصان چشم پزشکی است. این فرایند علاوه بر آنکه نیاز به تخصص بالا دارد، زمان بر و مستعد خطای انسانی است، به ویژه در مناطقی که تعداد متخصصان اندک است. از این رو، پژوهش های متعددی با هدف طراحی سیستم های کمکی هوشمند برای تحلیل و دسته بندی تصاویر شبکه در سال های اخیر انجام شده اند.

در مطالعات صورت گرفته، از رویکردهای مختلفی بهره گرفته شده است. برخی به صورت مستقیم از شبکه های یادگیری عمیق برای دسته بندی تصاویر استفاده کرده اند، در حالی که برخی دیگر ابتدا ویژگی هایی از تصاویر استخراج کرده و سپس با استفاده از الگوریتم های طبقه بندی کلاسیک مانند ماشین بردار پشتیبان (SVM)^۱ یا جنگل تصادفی^۲، اقدام به دسته بندی کرده اند.

در ادامه این فصل، پژوهش های مهمی که به طور خاص به تشخیص ROP از روی تصاویر پرداخته اند بررسی شده، و سپس مروری بر تکنیک ها و مدل هایی که در این حوزه رایج هستند، ارائه می شود. همچنین، با تحلیل مزایا و محدودیت های پژوهش های پیشین، زمینه انتخاب روش های مورد استفاده در این پروژه روشن تر خواهد شد.

^۱ Support Vector Machin

^۲ Random Forest

۲-۲- بررسی پژوهش‌های پیشین

پیشرفت‌های اخیر در حوزه یادگیری ماشین، به‌ویژه یادگیری عمیق، موجب شده‌اند که تحلیل تصاویر پزشکی با دقت و سرعت بالاتری نسبت به روش‌های سنتی انجام شود و یکی از حوزه‌های مورد توجه در پژوهش‌های اخیر تشخیص خودکار بیماری رتینوپاتی نوزادان زودرس با استفاده از تصاویر شبکیه است. مطالعات متعددی در این زمینه انجام شده که هدف مشترک آن‌ها طراحی سیستم‌های کمکی برای شناسایی سریع‌تر و دقیق‌تر بیماران نیازمند به درمان بوده است.

در مطالعه‌ای بزرگ شامل ۳۶,۲۳۱ عکس شبکیه از یک مرکز، مدلی با استفاده از شبکه عصبی ۱۰۱ لایه‌ای و شبکه‌های تشخیص منطقه‌ای^۱ طراحی شده است. این مدل توانسته دقت^۲ کلی در دسته‌بندی شدت ROP را به ۹۰.۳ درصد برساند؛ در دسته‌بندی «عادی»، «خفیف»، «نسبتاً ضروری» و «فوری» دقت‌ها به ترتیب ۸۸.۳، ۹۰، ۹۵.۷ و ۸۷ درصد بوده‌اند. حساسیت^۳ کلی حدود ۷۷.۸ و ویژگی^۴ حدود ۹۳.۲ برای طبقه‌بندی چهارگانه گزارش شده است و F1-Score^۵ حدود ۷۶.۱ بوده است و هنوز در تشخیص موارد ابتدایی بیماری چالش وجود دارد [3].

مطالعه‌ای دیگر با استفاده از بیش از ۵۲,۰۰۰ تصویر از مراکز مختلف در چین، یک پلتفرم چندبعدی ارائه داده است که شامل چند طبقه‌بندی هم‌زمان است (مثلاً کیفیت تصویر، وجود یا عدم وجود هر مرحله ROP، فرم‌های plus/pre-plus و غیره). در این مطالعه، معیار ROC-AUC برای دسته‌های مختلف بین ۹۸.۳ تا ۹۹.۸ بوده است؛ علاوه بر آن، حساسیت بین ۹۱.۸ تا ۹۸.۲ و ویژگی بین ۹۴.۹ تا ۹۹.۲ گزارش شده است [4].

رویکرد دیگری که در برخی مطالعات دیده می‌شود، استفاده از مدل‌های یادگیری عمیق از پیش آموزش دیده است. در اغلب این مطالعات، مدل‌های مورد نظر ابتدا روی مجموعه داده‌های بزرگ عمومی نظیر ImageNet آموزش دیده‌اند و سپس با استفاده از انتقال یادگیری^۵ برای کاربردهای پزشکی تطبیق داده شده‌اند. در یکی از مطالعات اخیر، یک مدل ترکیبی شامل یک شبکه عصبی کانولوشنی^۶ سبک و طبقه‌بند جنگل تصادفی برای تشخیص خودکار رتینوپاتی نوزادان نارس طراحی شده است. این مدل با هدف کاهش پیچیدگی محاسباتی و امکان استفاده در مراکز درمانی با منابع محدود

¹ Faster-RCNN

² Accuracy

³ Sensitivity

⁴ Specificity

⁵ Transfer Learning

⁶ Convolutional Neural Network

توسعه یافته و توانسته است با دقت ۹۴.۵ درصد، حساسیت ۹۴ درصد و ویژگی ۹۳ درصد، عملکرد بهتری نسبت به طبقه‌بندهای کلاسیک و مدل‌های پیش‌آموزش دیده داشته باشد [6].

در مطالعه‌ای، با استفاده از مدل EfficientNet برای پیش‌بینی ناحیه درگیر در شبکه، دقتی در حدود ۸۷.۳ درصد بدست آورده است. همچنین شاخص F1-Score در این پژوهش تقریباً ۸۸.۰۳ گزارش شده است [7].

در مجموع، پژوهش‌های پیشین نشان می‌دهند که روش‌های یادگیری عمیق، به‌ویژه مدل‌های مبتنی بر شبکه‌های عصبی کانولوشن و نسخه‌های انتقال یادگیری آن‌ها، توانسته‌اند در تشخیص خودکار بیماری ROP عملکرد قابل قبولی ارائه دهند. با این حال، در اغلب این مطالعات با چالش‌هایی نظیر کمبود داده، کیفیت متغیر تصاویر، عدم توازن بین کلاس‌ها و دشواری در تشخیص مراحل اولیه بیماری مواجه بوده‌اند.

یکی از محدودیت‌های اساسی این مدل‌ها، نیاز به حجم بالای داده‌های آموزشی برای دستیابی به عملکرد پایدار و قابل اطمینان است. در بسیاری از موارد، دسترسی به داده‌های کافی و برچسب‌گذاری شده در حوزه پزشکی دشوار و هزینه‌بر است. از طرفی، فرآیند آموزش این مدل‌ها نیز زمان‌بر بوده و نیازمند منابع محاسباتی قدرتمندی همچون پردازنده‌های گرافیکی است که استفاده از آن‌ها در برخی مراکز درمانی یا پژوهشی ممکن است محدود باشد.

بسیاری از مطالعات برای ارزیابی عملکرد مدل‌ها از معیارهایی مانند دقت، مساحت زیر منحنی ROC، حساسیت و ویژگی استفاده کرده‌اند، اما تعداد کمی از آن‌ها از معیار F1-score بهره برده‌اند؛ در حالی که این معیار به‌ویژه در شرایطی که داده‌ها نامتوازن باشند، اهمیت زیادی دارد و تصویر دقیق‌تری از عملکرد مدل ارائه می‌دهد.

در نتیجه، پژوهش حاضر تلاش دارد تا با بهره‌گیری از مدل‌های یادگیری عمیق به‌عنوان استخراج‌کننده ویژگی، و ترکیب آن‌ها با مجموعه‌ای از مدل‌های دسته‌بندی کلاسیک، سیستمی طراحی کند که ضمن حفظ دقت بالا، سازگار با زمان و منابع پردازشی محدود باشد. همچنین، با استفاده از معیارهایی مانند F1-score و ROC-AUC، تلاش شده است ارزیابی دقیق‌تری از عملکرد مدل‌ها، به‌ویژه در مواجهه با مجموعه داده‌های کوچک و نامتوازن، صورت گیرد.

۲-۳- جمع‌بندی پژوهش‌های پیشین

مرور مطالعات گذشته در زمینه تشخیص رتینوپاتی نوزادان زودرس نشان می‌دهد که روش‌های مبتنی بر یادگیری عمیق، به‌ویژه مدل‌های شبکه عصبی کانولوشن و روش‌های انتقال یادگیری، توانسته‌اند جایگزینی مناسب برای روش‌های سنتی

تشخیص پزشکی در این حوزه ارائه دهند. در بسیاری از پژوهش‌ها، عملکرد مدل‌ها در تشخیص ROP قابل قبول و در برخی موارد حتی نزدیک به عملکرد متخصصان انسانی گزارش شده است.

با این حال، همچنان چالش‌هایی مانند نیاز به داده‌های فراوان و با کیفیت، زمان‌بر بودن آموزش مدل‌ها، دشواری در تشخیص مراحل ابتدایی بیماری، و تمرکز محدود بر ابعاد مختلف بیماری (نظیر تشخیص نوع فرم یا مرحله آن) پابرجاست. علاوه بر این، اکثر مدل‌ها تنها در محیط‌های کنترل‌شده یا بر روی مجموعه داده‌های خاص مورد ارزیابی قرار گرفته‌اند و اعتبار آن‌ها در شرایط واقعی بالینی هنوز به‌طور کامل اثبات نشده است.

پژوهش‌های پیشین همچنین نشان می‌دهند که استفاده ترکیبی از مدل‌های یادگیری عمیق و الگوریتم‌های طبقه‌بندی کلاسیک می‌تواند راهکار مناسبی برای کاهش پیچیدگی آموزش، افزایش انعطاف‌پذیری و بهبود عملکرد در شرایط داده‌های محدود باشد. استفاده از معیارهایی مانند F1-score در کنار ROC-AUC نیز اهمیت بالایی در ارزیابی دقیق‌تر عملکرد مدل در شرایط نامتوازن دارد.

با وجود موفقیت‌های قابل توجه در پژوهش‌های پیشین، همچنان چالش‌هایی جدی در مسیر توسعه سیستم‌های تشخیص خودکار ROP وجود دارد. بسیاری از مطالعات از مجموعه داده‌های بزرگ، با برچسب‌گذاری تخصصی و منابع پردازشی قدرتمند بهره برده‌اند، اما در عمل، چنین امکاناتی در بسیاری از مراکز درمانی یا پژوهشی در دسترس نیست. همچنین، نتایج برخی مطالعات نشان داده‌اند که عملکرد مدل‌ها در شرایط واقعی، به‌ویژه در مواجهه با داده‌هایی از دوربین‌ها یا مراکز متفاوت، کاهش چشمگیری پیدا می‌کند. از سوی دیگر، در اکثر پژوهش‌ها تأکید اصلی بر تشخیص کلی بیماری یا طبقه‌بندی چندسطحی آن بوده، در حالی که در بسیاری از کاربردهای اولیه، نیاز اصلی صرفاً تشخیص وجود یا عدم وجود بیماری است.

بر این اساس، پژوهش حاضر با در نظر گرفتن محدودیت‌های فوق، رویکردی ترکیبی را در پیش گرفته است. در این پروژه، به جای آموزش کامل مدل‌های سنگین یادگیری عمیق، از مدل‌های از پیش آموزش‌دیده، صرفاً به‌عنوان استخراج‌کننده ویژگی^۱ استفاده شده است. سپس، این ویژگی‌ها به طبقه‌بندهای کلاسیکی داده شده‌اند تا طبقه‌بندی

^۱ Feature Extractor

دودویی^۱ تصاویر (وجود یا عدم وجود ROP) انجام گیرد. این انتخاب، ضمن کاهش پیچیدگی و زمان آموزش، امکان استفاده از داده‌های کمتر و منابع پردازشی محدودتر را نیز فراهم کرده است.

همچنین در طراحی ارزیابی عملکرد، با توجه به عدم توازن کلاس‌ها در داده‌های پزشکی، از معیارهایی مانند F1-Score و ROC-AUC در کنار دقت استفاده شده تا تصویر دقیق‌تری از کارایی مدل به دست آید. این پروژه تلاش دارد الگویی واقع‌بینانه و قابل اجرا برای شرایط عملی ارائه دهد؛ الگویی که با وجود داده‌های محدود، همچنان بتواند تشخیص قابل اعتماد و کاربردی ارائه کند.

^۱ Binary Classification

۳- تعاریف

۳-۱- مدل‌های یادگیری عمیق مورد استفاده

در این پژوهش، از شش مدل شناخته‌شده و معتبر از خانواده‌ی شبکه‌های عصبی کانولوشنی (CNN) بهره گرفته شد که همگی پیش‌تر بر روی مجموعه‌داده‌ی ImageNet آموزش دیده‌اند. هدف از انتخاب این مدل‌ها، ارزیابی توانمندی آن‌ها در استخراج ویژگی‌های مؤثر از تصاویر شبکه چشم نوزادان زودرس و کاربرد آن در تشخیص خودکار بیماری رتینوپاتی بود. در مرحله‌ی نخست از پژوهش، این مدل‌ها بدون اعمال تغییرات عمده و صرفاً با آموزش مجدد لایه‌ی نهایی، به‌صورت مستقیم برای طبقه‌بندی تصاویر به دو گروه دارای ROP و فاقد ROP به کار گرفته شدند. اما در مراحل بعدی، چهار مدل از میان این شش مدل که عملکرد بهتری از خود نشان دادند، انتخاب شدند تا به‌عنوان استخراج‌کننده‌ی ویژگی و در ترکیب با طبقه‌بندهای کلاسیک مورد استفاده قرار گیرند. در ادامه، ساختار معماری، ویژگی‌های فنی، دلایل انتخاب نسخه‌ی خاص هر مدل، و نقش آن‌ها در فرآیند پژوهش به تفصیل مورد بررسی قرار می‌گیرد.

ResNet50

نخستین مدل مورد استفاده، شبکه‌ی ResNet50 بود. این مدل یکی از دستاوردهای مهم مایکروسافت در حوزه‌ی بینایی ماشین به‌شمار می‌رود که با معرفی مفهوم «بلوک‌های باقی‌مانده»^۱ تحولی اساسی در طراحی شبکه‌های عمیق ایجاد کرد. در معماری این شبکه، با افزودن مسیرهای میان‌بر^۲ میان لایه‌ها، امکان انتقال اطلاعات اولیه به لایه‌های عمیق‌تر فراهم می‌شود و بدین ترتیب، از بروز پدیده‌ی ناپدید شدن گرادیان جلوگیری می‌گردد. این سازوکار، به‌ویژه در شبکه‌هایی با تعداد لایه‌ی زیاد، باعث پایداری بهتر در آموزش و امکان یادگیری ویژگی‌های انتزاعی پیچیده‌تر می‌شود. نسخه‌ی ResNet50 با داشتن ۵۰ لایه‌ی قابل آموزش، توازن میان عمق مناسب برای استخراج اطلاعات و بار محاسباتی قابل قبول ایجاد می‌کند. از این نظر، در مقایسه با نسخه‌های سبک‌تر مانند ResNet18 یا نسخه‌های سنگین‌تر همچون ResNet101، گزینه‌ای

^۱ Residual Blocks

^۲ Shortcut Connections

میان‌رده با کارایی قابل توجه به‌شمار می‌آید. پس از حذف لایه‌ی نهایی در این مدل، خروجی به‌صورت برداری با ۲۰۴۸ ویژگی به‌دست می‌آید که می‌تواند در کاربردهای متنوع طبقه‌بندی مورد استفاده قرار گیرد.

EfficientNetB0

مدل دوم، EfficientNetB0، از جمله معماری‌های نوین و بهینه‌سازی‌شده است که توسط تیم Google Brain توسعه یافته و در سال‌های اخیر توجه بسیاری را به خود جلب کرده است. این شبکه، بر پایه‌ی الگوریتم جستجوی معماری عصبی^۱ طراحی شده و با رویکردی، سه مؤلفه‌ی عمق، عرض و وضوح تصویر را به‌صورت هم‌زمان مقیاس‌گذاری می‌کند. EfficientNetB0 به‌عنوان نسخه‌ی پایه‌ی این خانواده، ضمن برخورداری از ساختاری سبک، دقت قابل قبولی ارائه می‌دهد. این با استفاده از کانولوشن‌های جدانشدنی عمقی و ساختارهای میان‌بر خطی، حافظه و منابع محاسباتی مورد نیاز را به حداقل رسانده است. خروجی این شبکه در مرحله‌ی پیش از لایه‌ی طبقه‌بندی نهایی، برداری با ۱۲۸۰ بعد است که امکان بهره‌گیری از آن در فرآیندهای استخراج ویژگی فراهم می‌سازد.

MobileNetV2

سومین مدل، MobileNetV2 است که از جمله شبکه‌های سبک و سریع محسوب می‌شود و به‌طور خاص برای کاربرد در دستگاه‌های همراه و سیستم‌های تعبیه‌شده طراحی شده است و از تکنیک کانولوشن‌های جدانشدنی عمقی برای کاهش پارامترها و افزایش کارایی بهره می‌برد. تفاوت کلیدی نسخه‌ی دوم نسبت به نسخه‌ی اول این معماری، افزودن میان‌برهای خطی و بهینه‌سازی مسیر عبور اطلاعات در لایه‌های باریک‌تر است. خروجی نهایی این شبکه نیز برداری با ۱۲۸۰ بعد است که برای استخراج ویژگی‌های میان‌رده از تصاویر، قابل استفاده خواهد بود. این مدل به‌دلیل ساختار کم‌حجم و اجرای سریع، در بسیاری از سامانه‌های واقعی و کاربردهای بلادرنگ مطرح است.

DenseNet121

چهارمین مدل مورد بررسی، DenseNet121 می‌باشد. این مدل که در ادامه‌ی مسیر بهینه‌سازی شبکه‌های عمیق ارائه شده، رویکردی مبتنی بر اتصالات چگال (Dense Connections) را به کار می‌گیرد. در این ساختار، هر لایه به‌جای دریافت خروجی تنها از لایه‌ی قبل، ورودی خود را از تمامی لایه‌های قبلی دریافت می‌کند. این ویژگی، موجب بازاستفاده‌ی گسترده‌تر از ویژگی‌ها و کاهش چشم‌گیر تکرار اطلاعات در لایه‌ها می‌شود. DenseNet121 با وجود

^۱ Neural Architecture Search

آنکه از ۱۲۱ لایه تشکیل شده است، اما به دلیل استفاده‌ی مؤثر از پارامترها، دارای پیچیدگی محاسباتی نسبتاً کمتری در مقایسه با سایر شبکه‌های مشابه با عمق بالا می‌باشد. خروجی این مدل نیز به صورت بردار ویژگی با ۱۰۲۴ بعد به دست می‌آید که توان بالایی در تحلیل تصاویر پزشکی با جزئیات پیچیده دارد.

InceptionV3

مدل پنجم، InceptionV3 نام دارد که با هدف ایجاد تعادل میان دقت بالا و بهره‌وری محاسباتی، توسط تیم Google معرفی شده است. این شبکه با استفاده از معماری چندمسیره (Multi-Path) در هر بلاک، امکان تحلیل هم‌زمان ویژگی‌ها در مقیاس‌های متفاوت را فراهم می‌سازد. در InceptionV3، مسیرهایی با فیلترهای کانولوشن مختلف به صورت موازی عمل می‌کنند که موجب افزایش قدرت تفکیک و کاهش وابستگی به یک نوع خاص از فیلتر می‌شود. خروجی این مدل، بردار ویژگی با ۲۰۴۸ بعد است که در تحلیل‌های مبتنی بر طبقه‌بندی قابل استفاده خواهد بود.

VGG16

ششمین و آخرین مدل مورد بررسی، VGG16 است؛ مدلی کلاسیک که علی‌رغم گذشت بیش از یک دهه از معرفی آن توسط دانشگاه آکسفورد، همچنان در کاربردهای مختلف مورد توجه است. این شبکه از ۱۶ لایه‌ی وزن‌دار تشکیل شده و ساختار آن مبتنی بر استفاده‌ی پیاپی از لایه‌های کانولوشن با فیلترهای کوچک (۳×۳) و لایه‌های Pooling است. مزیت اصلی VGG16 در سادگی ساختار و قابل درک بودن آن نهفته است که امکان تحلیل دقیق عملکرد لایه‌ها و ویژگی‌های استخراج‌شده را فراهم می‌سازد. با وجود اینکه این مدل نسبت به معماری‌های جدیدتر دارای پارامترهای بسیار بیشتری است، اما به دلیل پایداری و عملکرد نسبتاً مناسب، همچنان جایگاه خود را در میان مدل‌های مبنای حفظ کرده است. خروجی نهایی VGG16 پس از حذف لایه‌ی آخر، برداری با ۲۵۶۰ ویژگی خواهد بود.

در مجموع، هر یک از این شش مدل دارای ساختار و مزایای منحصر به فردی هستند که آن‌ها را برای بهره‌گیری در بخش‌های مختلف پژوهش مناسب ساخته است. در بخش‌های آتی، شیوه‌ی استفاده از این مدل‌ها در مراحل مختلف پژوهش از جمله آموزش، استخراج ویژگی و ترکیب با طبقه‌بندهای کلاسیک، به تفصیل بیان خواهد شد.

۳-۲- معیارهای ارزیابی عملکرد مدل‌ها

در ارزیابی عملکرد مدل‌های تشخیص و دسته‌بندی، به‌ویژه در مسائل دسته‌بندی دودویی (شامل دو کلاس)، استفاده از معیارهای آماری دقیق امری ضروری است. در این پژوهش، برای سنجش کیفیت پیش‌بینی مدل‌ها، از پنج معیار اصلی شامل دقت، دقت مثبت، حساسیت یا بازیابی، امتیاز $F1$ و مساحت زیر منحنی ROC استفاده شده است. این شاخص‌ها در تمام مراحل تحقیق برای مقایسه‌ی کارایی مدل‌های مختلف به کار رفته‌اند و امکان تحلیل دقیق‌تری از نقاط قوت و ضعف هر روش را فراهم کرده‌اند.

برای تعریف این معیارها، ابتدا لازم است با مفاهیم پایه‌ای جدول درهم‌ریختگی^۱ آشنا شویم.

- True Positive (TP): مواردی که به‌درستی به‌عنوان مثبت (دارای بیماری) تشخیص داده شده‌اند.
- True Negative (TN): مواردی که به‌درستی به‌عنوان منفی (فاقد بیماری) تشخیص داده شده‌اند.
- False Positive (FP): مواردی که به‌اشتباه به‌عنوان مثبت تشخیص داده شده‌اند.
- False Negative (FN): مواردی که به‌اشتباه به‌عنوان منفی تشخیص داده شده‌اند.

بر اساس این مقادیر، معیارهای ارزیابی عملکرد تعریف می‌شوند.

		Actual	
		positive	negative
Predicted	positive	TP	FP
	negative	FN	TN

شکل ۱- ماتریس درهم‌ریختگی

^۱ Confusion Matrix

۳-۲-۱. دقت (Accuracy)

صحت، ساده‌ترین و رایج‌ترین معیار ارزیابی عملکرد طبقه‌بند است و همانطور که از رابطه (۱) مشخص است نسبت تعداد پیش‌بینی‌های صحیح به کل پیش‌بینی‌ها را نشان می‌دهد.

$$Accuracy = \frac{TP+TN}{FP+FN+TP+TN} \quad (۱)$$

این معیار نشان می‌دهد که مدل، چند درصد از نمونه‌ها را (چه مثبت و چه منفی) به درستی طبقه‌بندی کرده است. با این حال، در مجموعه داده‌هایی با توزیع نامتوازن (که یک کلاس غالب است)، ممکن است صحت به تنهایی گمراه‌کننده باشد.

۳-۲-۲. صحت (Precision)

نسبت نمونه‌های مثبت درست (TP) به تمامی نمونه‌های مثبت پیش‌بینی شده را صحت یا Precision گویند. در این معیار همانطور که از رابطه (۲) مشخص است، مخرج، پیش‌بینی مثبت مدل برای تمامی نمونه‌های موجود در مجموعه داده است [7]. به بیان ساده‌تر، معیار دقت به این پرسش پاسخ می‌دهد که از میان تمامی مراجعہ کنندگانی که مثبت تشخیص داده شده‌اند، چند نسبتی در حقیقت نیز بیمار هستند.

$$Precision = \frac{TP}{TP+FP} \quad (۲)$$

این معیار میزان خطای مثبت کاذب را کنترل می‌کند و برای کاربردهایی که هزینه‌ی خطای مثبت بالاست، اهمیت زیادی دارد.

۳-۲-۳. بازیابی (Recall)

بازیابی یا Sensitivity (و در برخی منابع، True Positive Rate) همانطور که از رابطه (۳) مشخص است؛ معیاری است که نشان می‌دهد از میان تمام نمونه‌های واقعاً مثبت، چند درصد توسط مدل شناسایی شده‌اند [7].

$$Recall = \frac{TP}{TP+FN} \quad (۳)$$

این معیار در کاربردهای پزشکی که عدم شناسایی یک مورد بیمار می تواند پیامد جدی داشته باشد، از اهمیت زیادی برخوردار است.

۴-۲-۳. امتیاز F1 (F1-Score)

امتیاز F1 همانطور که از رابطه (۴) مشخص است ترکیبی از دو معیار دقت و بازیابی است. از آنجایی که هر دو معیار دقت و بازیابی در محاسبه امتیاز F1 نقش دارند، امتیاز F1 بالاتر نشان دهنده عملکرد بهتر است. همانطور که در فرمول این معیار نیز مشخص است، به دلیل وجود عملگر ضرب در صورت مخرج، اگر از میزان یکی از معیارهای دقت یا بازیابی کاسته شود، امتیاز F1 بسیار نزولی می شود. در نتیجه امتیاز F1 یک مدل یادگیری ماشین بالاست، اگر نمونه های مثبت پیش بینی شده در حقیقت نیز مثبت بوده و هیچ نمونه مثبتی به اشتباه منفی پیش بینی نشده باشد [7].

$$F1 - Score = \frac{2.Precision.Recall}{Precision + Recall} \quad (۴)$$

F1-Score در شرایطی که داده ها نامتوازن هستند، معیاری مناسب تر نسبت به Accuracy محسوب می شود.

۴-۲-۵. مساحت زیر منحنی ROC

معیار ROC-AUC نشان دهنده عملکرد کلی مدل در تمامی آستانه های ممکن است. منحنی ROC از رسم True Positive Rate در برابر False Positive Rate در آستانه های مختلف حاصل می شود و مساحت زیر این منحنی (AUC) نمایانگر قابلیت مدل در تفکیک دو کلاس است.

مقدار AUC بین ۰ تا ۱ است و هرچه به ۱ نزدیک تر باشد، نشان دهنده قدرت تفکیک بالاتر مدل است. در بسیاری از پژوهش ها، مساحت زیر سطح منحنی ROC به عنوان معیار استاندارد برای مقایسه ی نهایی عملکرد مدل ها پذیرفته شده است.

۴- کارهای انجام شده و روش پیشنهادی

۴-۱- مقدمه

در این فصل، روند کامل انجام پروژه از مرحله آماده‌سازی داده‌ها تا طراحی مدل‌ها و ارزیابی نهایی آن‌ها شرح داده می‌شود. با توجه به هدف اصلی پروژه که تشخیص دودویی بیماری رتینوپاتی نوزادان زودرس با استفاده از تصاویر شبکه‌ای است، ابتدا منبع داده و ویژگی‌های آن معرفی شده و سپس مراحل طراحی مدل‌های یادگیری عمیق، استخراج ویژگی، استفاده از طبقه‌بندهای کلاسیک، پیش‌پردازش داده و در نهایت مقادیر بدست آمده برای ارزیابی عملکرد مدل‌ها بیان خواهند شد.

هدف این فصل، ارائه‌ی تصویری شفاف از مراحل مختلف انجام پروژه است؛ این توضیحات کمک می‌کنند که روش انجام کار بهتر درک شود و منطق انتخاب ابزارها و مراحل مختلف روشن‌تر گردد.

۴-۲- روند کلی

پروژه حاضر با هدف طراحی یک سیستم طبقه‌بندی دودویی برای تشخیص بیماری رتینوپاتی نوزادان زودرس بر اساس تصاویر شبکه‌ای، در چند مرحله متوالی اجرا شده است. در ابتدا، تصاویر شبکه‌ای از یک پایگاه داده معتبر جمع‌آوری و سازمان‌دهی شدند. سپس، مجموعه‌ای از مدل‌های یادگیری عمیق از پیش آموزش‌دیده بر روی مجموعه داده Imagenet برای دسته‌بندی این تصاویر استفاده شدند. در این مرحله، فقط لایه‌های انتهایی مدل‌ها یا همان لایه طبقه‌بندی آموزش داده شد تا طبق شرایط پژوهش قابلیت دسته‌بندی دودویی (وجود بیماری یا عدم وجود آن) را داشته باشند، اما ساختار اصلی مدل‌ها ثابت باقی ماند.

پس از بررسی نتایج مدل‌های مختلف، چهار مدل با عملکرد بهتر انتخاب شدند تا به عنوان استخراج‌کننده ویژگی مورد استفاده قرار گیرند. از این مدل‌ها، بدون انجام آموزش مجدد، برای استخراج بردار ویژگی از تصاویر استفاده شد. در ادامه، این ویژگی‌ها به عنوان ورودی به چند الگوریتم طبقه‌بندی کلاسیک شامل Regression Logistic، SVM،

K-NN، Random Forest و XGBoost داده شدند تا فرایند دسته‌بندی تصاویر انجام شود. همچنین با توجه به ابعاد بالای بردارهای ویژگی استخراج شده از مدل‌های یادگیری عمیق، و کاهش عملکرد برخی طبقه‌بندهای کلاسیک در مواجهه با ویژگی‌های با ابعاد بالا، از روش تحلیل مؤلفه‌های اصلی (PCA^1) برای کاهش بعد ویژگی‌ها بهره گرفته شد.

پس از اجرای اولیه مدل‌ها، برای بهبود عملکرد سیستم، برخی اقدامات تکمیلی روی داده‌ها و ویژگی‌ها انجام شد. در ابتدا، برای هر بیمار فقط یک تصویر در نظر گرفته شده بود، اما در ادامه، برای افزایش تنوع و غنای داده‌ها، از چند تصویر مختلف از هر بیمار استفاده شد. شایان ذکر است، در هر دو حالت (یک تصویر و چند تصویر)، به منظور رفع عدم توازن بین کلاس‌ها، از روش SMOTE جهت افزایش نمونه‌های کلاس اقلیت در مجموعه‌ی آموزش² استفاده شد.

در مرحله‌ای دیگر عملیاتی پیش پردازشی بر روی عکس‌های پایگاه داده انجام شد تا کیفیت تصاویر بهبود یابد و اطلاعات مهم هر تصویر مانند نواحی خون‌ریزی و رگ‌ها وضوح بیشتری در عکس داشته باشند.

در نهایت، برای ارزیابی عملکرد مدل‌ها از معیارهایی مانند دقت، امتیاز $F1^3$ و مساحت زیر منحنی ROC استفاده شد تا مدل‌ها در شرایط داده‌های نامتوازن نیز به خوبی سنجیده شوند.

۴-۳- پایگاه داده پژوهش

در این پژوهش از یک مجموعه داده‌ی ساختاریافته و جامع شامل ۶۰۰۰۴ تصویر شبکه‌ای از ۱۸۸ نوزاد استفاده شده است. این مجموعه داده در بیمارستان دانشگاهی Ostrava در جمهوری چک و تحت نظارت بالینی متخصصان چشم‌پزشکی اطفال گردآوری شده است [1]. هدف اصلی از تشکیل این پایگاه داده، فراهم آوردن بستری واقعی برای توسعه‌ی مدل‌های هوش مصنوعی جهت تشخیص، پایش و تحلیل خودکار رتینوپاتی نوزادان نارس بوده است؛ بیماری‌ای که با رشد غیرطبیعی عروق خونی شبکه در نوزادان زودرس همراه است و یکی از علل اصلی نابینایی در کودکان به‌شمار می‌رود.

¹ Principal Component Analysis

² Train Set

³ F1-score

فرآیند تصویربرداری در قالب برنامه‌ی غربالگری منظم برای نوزادانی انجام شده که سن بارداری^۱ کمتر از ۳۲ هفته و وزن تولد کمتر از ۱۵۰۰ گرم داشته‌اند. همچنین، برخی نوزادان با سن بالاتر یا وزن بیشتر، در صورت داشتن وضعیت بالینی ناپایدار مانند نیاز به اکسیژن درمانی نیز در برنامه‌ی تصویربرداری قرار گرفته‌اند.

در جمع‌آوری این پایگاه داده برای ثبت تصاویر، از سه سامانه‌ی تصویربرداری دیجیتال شبکه استفاده شده است.

• Clarity RetCam 3

• Natus RetCam Envision

• Phoenix ICON

این دستگاه‌ها از رایج‌ترین تجهیزات تخصصی در تصویربرداری غیرمستقیم شبکه در نوزادان هستند. تصویربرداری توسط چشم‌پزشک متخصص انجام شده و نواحی مختلفی از شبکه شامل قسمت مرکزی و چهار ناحیه‌ی محیطی در هر چشم ثبت شده‌اند.

تمام تصاویر به صورت رنگی، با وضوح بالا و بدون فشرده‌سازی ذخیره شده‌اند. مجموعه داده شامل تصاویر مربوط به یک یا چند نوبت تصویربرداری برای اغلب بیماران است؛ به طوری که از ۱۴۰ نوزاد بیش از یک بار تصویربرداری انجام شده و در برخی موارد، یک سری تصویربرداری حاوی چند تصویر متوالی است.

هر تصویر در این پایگاه داده با قالبی مشخص نامگذاری شده بطوریکه نام هر تصویر به ترتیب نشان دهنده مقادیر زیر است.

- شناسه‌ی ناشناس بیمار
- جنسیت (۹۴ پسر، ۹۴ دختر)
- سن بارداری در هنگام تولد (میانگین ۳۳ هفته، حداقل ۲۳ هفته، حداکثر ۴۱ هفته)
- وزن هنگام تولد (میانگین ۲۰۱۷ گرم، با حداقل ۴۸۰ و حداکثر ۴۰۸۰ گرم)
- سن پسابرداری در هنگام تصویربرداری
- سری تصویربرداری (برای شناسایی نوبت تصویربرداری)

¹ Gestational Age

- نوع دستگاه تصویربرداری
- ناحیه‌ی مورد تصویربرداری از شبکه
- کد تشخیص پزشکی


کد تشخیص هر تصویر در قالب یک عدد صحیح بین ۰ تا ۱۳ ثبت شده است که نشان‌دهنده‌ی وضعیت مرحله‌ی بیماری در لحظه‌ی تصویربرداری است. این کدها شامل وضعیت فاقد ROP (کد ۰) تا مراحل پیشرفته‌ی بیماری، مانند انواع شدید ROP، می‌باشد. در شروع این پژوهش، با استناد به کد تشخیص ثبت‌شده برای هر تصویر، برچسب‌گذاری به‌صورت دودویی انجام گرفت؛ به‌گونه‌ای که نمونه‌هایی با کد ۰ در گروه فاقد بیماری (منفی) و سایر کدها (۱ تا ۱۳) در گروه دارای ROP (مثبت) قرار گرفتند. این برچسب‌گذاری اولیه، مبنای طبقه‌بندی دودویی تصاویر در مراحل مختلف پژوهش قرار گرفت. در مجموع ۸۰ نوزاد در این مجموعه داده مبتلا به بیماری ROP بوده و ۱۲۸ نوزاد به این بیماری مبتلا نبوده‌اند.

تصاویر دارای تنوع قابل توجهی در نور، وضوح، زاویه و کیفیت کلی هستند که بخشی از آن ناشی از تفاوت در دستگاه‌های تصویربرداری، مهارت اپراتورها، حرکات نوزاد و شرایط بالینی مختلف است. این تنوع، موجب افزایش شباهت داده‌ها به محیط‌های بالینی واقعی شده.

این پایگاه داده، با حذف کامل اطلاعات هویتی و رعایت کامل اصول اخلاق در پژوهش، به صورت کاملاً ناشناس و بدون امکان شناسایی مجدد بیماران منتشر شده و در دسترس محققان حوزه‌ی سلامت قرار گرفته است.



شکل ۲ - نمونه تصویر مبتلا به ROP



شکل ۳ - نمونه تصویر شبکیه بدون بیماری ROP

۴-۴- تشخیص خودکار بیماری ROP با بهره‌گیری از شبکه‌های عصبی یادگیری عمیق

پیش‌آموزش دیده

در نخستین مرحله از اجرای پژوهش، هدف آن بود که عملکرد مستقیم مدل‌های پیش‌آموزش‌دیده‌ی یادگیری عمیق، در تشخیص اولیه‌ی رتینوپاتی نوزادان نارس مورد ارزیابی قرار گیرد. بدین منظور، از پایگاه داده معرفی‌شده، برای هر یک از ۱۸۸ نوزاد، تنها اولین تصویر ثبت‌شده انتخاب شد تا مجموعه‌ای از تصاویر تک‌نمونه‌ای تشکیل شود.

در این مرحله، از شش مدل شناخته‌شده‌ی شبکه‌ی عصبی کانولوشنی که در بخش پیشین معرفی شدند، شامل VGG16، InceptionV3، DenseNet121، MobileNetV2، EfficientNetB0، ResNet50 استفاده شد. این مدل‌ها همگی به‌صورت پیش‌آموزش‌دیده بر روی مجموعه‌داده‌ی ImageNet موجود بودند. با این حال، به‌دلیل اینکه لایه‌ی نهایی این شبکه‌ها برای مسئله‌ی دسته‌بندی چندکلاسه‌ی ImageNet طراحی شده است و نه برای طبقه‌بندی دودویی (مثبت/منفی)، نیاز به بازآموزی لایه‌ی خروجی وجود داشت.

در این مرحله، ساختار اصلی مدل‌ها به‌صورت فریزشده و بدون تغییر حفظ شد و تنها لایه‌ی نهایی یا همان لایه طبقه‌بند مجدداً آموزش داده شد. به‌عبارتی، شبکه به‌عنوان استخراج‌کننده‌ی اولیه‌ی ویژگی عمل می‌کرد و تنها پارامترهای لایه‌ی انتهایی آن با داده‌های جدید به‌روزرسانی می‌شدند.

برای آموزش این لایه، کل داده‌ها، یا به عبارتی ۱۸۸ نمونه به نسبت‌های مشخص به سه بخش تقسیم شدند.

- ۶۰ درصد برای مجموعه آموزش

- ۱۰ درصد برای مجموعه اعتبارسنجی^۱

- ۲۰ درصد برای مجموعه تست^۲

این تقسیم‌بندی با حفظ توزیع نسبی^۳ نمونه‌های مثبت و منفی در هر بخش انجام شد تا از عدم تعادل کلاس‌ها در مجموعه‌های فرعی جلوگیری شود.

^۱ Validation Set

^۲ Test Set

^۳ Stratified Split

شبکه‌ها بر روی مجموعه‌ی آموزشی آموزش دیدند، و عملکرد نهایی آن‌ها بر اساس پیش‌بینی روی داده‌های تست ارزیابی شد. شایان ذکر است که در تمامی مراحل این پژوهش، محیط توسعه‌ی کدنویسی با زبان پایتون و با بهره‌گیری از کتابخانه‌های استاندارد و شناخته‌شده‌ی TensorFlow (برای بارگذاری مدل‌های پیش‌آموزش دیده و انجام یادگیری) و Scikit-learn (برای ارزیابی مدل‌ها و گزارش نتایج) طراحی شده است. کدهای پیاده‌سازی شده، علاوه بر آموزش مدل‌ها، تمامی نتایج ارزیابی را ذخیره کرده‌اند تا در بخش‌های بعدی تحلیل آماری روی آن‌ها انجام شود.

نتایج این مرحله از پژوهش در جدول ۱ قابل مشاهده است. می‌توان دید بطور کلی مدل ResNet50 در این مقطع بهترین عملکرد را در هر ۴ معیار نشان داده است.

جدول ۱

Row	مدل	Accuracy	Precision	Recall	F1-score
1	ResNet50	0.791	0.839	0.682	0.704
2	VGG16	0.705	0.649	0.626	0.625
3	InceptionV3	0.651	0.591	0.598	0.599
4	EfficientNetB0	0.633	0.595	0.601	0.593
5	MobileNetV2	0.657	0.587	0.589	0.581
6	DenseNet121	0.536	0.551	0.563	0.544

۴-۵- تشخیص ROP با بهره‌گیری از استخراج ویژگی و مدل‌های یادگیری ماشین

۴-۵-۱. روش پیاده‌سازی و مراحل

در گام دوم از فرآیند پژوهش، تمرکز بر بهره‌گیری از شبکه‌های عصبی کانولوشنی عمیق به‌عنوان ابزار استخراج ویژگی‌های تصویر قرار گرفت. در این مرحله، برخلاف مرحله‌ی پیشین، مدل‌های یادگیری عمیق از حالت آموزشی خارج شده و بدون هیچ‌گونه یادگیری یا آموزش مجدد، صرفاً به‌منظور استخراج بردار ویژگی از تصاویر استفاده شدند.

خروجی نهایی هر مدل، پس از حذف لایه‌های طبقه‌بندی، برداری با ابعاد مشخص بود که بیانگر ویژگی‌های استخراج شده از تصویر ورودی به‌شمار می‌رفت.

چهار مدل از میان شش مدل بررسی شده‌ی قبلی که در مرحله‌ی نخست عملکرد مطلوب‌تری ارائه داده بودند، برای ادامه‌ی کار به عنوان استخراج کننده ویژگی انتخاب شدند. این مدل‌ها شامل InceptionV3، VGG16، ResNet50 و EfficientNetB0 بودند. برای هر یک از این مدل‌ها مانند مرحله قبل، تعداد ۱۸۸ تصویر (شامل اولین تصویر ثبت شده از هر بیمار) به عنوان ورودی داده شد و بردار ویژگی مربوط به هر تصویر استخراج گردید. این بردارها سپس به عنوان داده‌ی ورودی به مجموعه‌ای از مدل‌های طبقه‌بندی کلاسیک منتقل شدند تا عملکرد آن‌ها در دسته‌بندی دودویی بیماری (مثبت/منفی) مورد ارزیابی قرار گیرد.

طبقه‌بندهای مورد استفاده در این پژوهش از بین رایج ترین طبقه‌بندی های کلاسیک انتخاب شدند. مدل‌های مورد استفاده شامل الگوریتم‌های زیر بودند.

• Logistic Regression

• Support Vector Machine (SVM)

• Random Forest

• K-Nearest Neighbors (KNN)

• Gradient Boosting

• XGBoost

این الگوریتم‌ها با استفاده از کتابخانه‌های استاندارد یادگیری ماشین نظیر Scikit-learn و XGBoost پیاده‌سازی شدند. ابتدا داده‌ها با نسبت ۷۰ درصد برای آموزش، ۱۰ درصد برای اعتبارسنجی و ۲۰ درصد برای آزمون نهایی تقسیم شدند. کلیه مراحل آموزش طبقه‌بندها بر روی داده‌های آموزشی انجام گرفت و پس از آن، عملکرد مدل‌ها با استفاده از مجموعه‌ی تست، بر اساس معیارهای معرفی شده شامل دقت، صحت، بازیابی، F1-score و مساحت زیر منحنی ROC ارزیابی شد.

از آنجا که ابعاد بردارهای ویژگی استخراج شده از مدل‌های یادگیری عمیق معمولاً بسیار بالا است (برای مثال، ۲۰۴۸ ویژگی در خروجی ResNet50)، جهت کاهش پیچیدگی محاسباتی، حذف ابعاد غیر مؤثر، و جلوگیری از بیش‌برازش^۱، از روش PCA برای کاهش بعد استفاده شد. به صورت مشخص، در این پژوهش، برای هر بردار ویژگی، ۱۰۰ مؤلفه اصلی اول که بیش‌ترین واریانس داده را پوشش می‌دادند، انتخاب و برای آموزش طبقه‌بندها مورد استفاده قرار گرفتند.

کاهش بعد با PCA مزایای متعددی دارد که از جمله مزایای آن می‌توان به موارد زیر اشاره کرد.

- تسریع زمان آموزش و پیش‌بینی
 - کاهش نویز در داده‌ها
 - حذف ویژگی‌های هم‌بسته و تکراری
 - و ایجاد بستری برای یادگیری مؤثرتر توسط مدل‌های کلاسیک با داده‌های کوچک‌تر
- با توجه به نامتوازن بودن توزیع کلاس‌ها در داده‌های اولیه (تعداد تصاویر ROP مثبت نسبت به ROP منفی کمتر بود)، از تکنیک SMOTE برای بالانس‌سازی کلاس‌ها در مجموعه‌ی آموزش استفاده شد. این روش با تولید نمونه‌های مصنوعی از کلاس اقلیت بر پایه‌ی فاصله‌ی میان نمونه‌ای در فضای ویژگی، مجموعه‌ی آموزش را متوازن کرده و از بروز سوگیری طبقه‌بند به سمت کلاس غالب جلوگیری نمود.

لازم به ذکر است که اعمال SMOTE صرفاً بر روی مجموعه‌ی آموزش صورت گرفت و مجموعه‌های اعتبارسنجی و آزمون نهایی به صورت دست‌نخورده باقی ماندند تا نتایج مدل‌ها بر پایه‌ی داده‌های واقعی ارزیابی شوند.

یکی از جنبه‌های مهم تحلیل عملکرد در این مرحله، اندازه‌گیری زمان مورد نیاز برای استخراج ویژگی از تصاویر بود. برای هر یک از مدل‌های مورد استفاده، زمان صرف‌شده برای پردازش ۱۸۸ تصویر به صورت جداگانه ثبت شد تا در کنار معیارهای دقت، بازیابی و F1، یک دید جامع از کارایی عملیاتی مدل‌ها فراهم شود. این زمان شامل تولید بردارهای ویژگی، زمان آموزش و زمان تست بود.

در جدول ۲، ۳ نتیجه برتر از ترکیب هر استخراج کننده ویژگی با طبقه‌بندها قابل مشاهده است. نتایج این مرحله از پژوهش نشان می‌دهد که ترکیب مدل‌های EfficientNetB0 و Logistic Regression بصورت معناداری عملکرد

^۱ Overfitting

بهتری از دیدگاه امتیاز F1 و دقت نسبت به سایر ترکیب‌ها داشته است. همچنین از دیدگاه مساحت زیر منحنی ROC عملکرد ترکیب‌های EfficientNetB0، SVM و Logistic Regression قابل مقایسه و نسبت به سایر ترکیب‌ها عملکرد بهتری داشته‌اند.

همچنین در جدول ۳ مدت زمان صرف شده برای استخراج ویژگی از ۱۸۸ عکس برای هر مدل از استخراج کنندگان ویژگی نشان داده شده است. در این پژوهش زمان در همه مراحل در محیط Google Colab با استفاده از سخت افزار پایه آن اندازه گیری شده است. همانطور که در این جدول مشخص است از این بین این ۴ مدل بهترین عملکرد زمانی را شبکه عصبی EfficientNetB0 داشته است.

جدول ۲

ROC-AUC	F1-Score	Recall	Precision	Accuracy	مدل طبقه‌بندی	مدل استخراج ویژگی
0.842	0.818	0.8205	0.8172	0.820	Logistic Regression	EfficientNetB0
0.845	0.766	0.769	0.764	0.769	SVM	EfficientNetB0
0.793	0.766	0.769	0.764	0.769	XGBoost	EfficientNetB0
0.787	0.751	0.743	0.775	0.743	Logistic Regression	ResNet50
0.805	0.748	0.743	0.757	0.743	SVM	ResNet50
0.706	0.647	0.641	0.658	0.641	Random Forest	ResNet50
0.751	0.728	0.717	0.785	0.717	KNN	VGG16
0.780	0.714	0.717	0.711	0.717	SVM	VGG16
0.723	0.672	0.692	0.667	0.692	Random Forest	VGG16

0.654	0.705	0.717	0.701	0.717	SVM	InceptionV3
0.509	0.662	0.666	0.659	0.666	Gradient Boosting	InceptionV3
0.430	0.651	0.666	0.644	0.666	Random Forest	InceptionV3

جدول ۳

مدل استخراج ویژگی	زمان استخراج ویژگی (ثانیه)
EfficientNetB0	16.553
ResNet50	51.294
VGG16	85.161
InceptionV3	21.262

۴-۶- تحلیل اثر افزایش نمونه از هر بیمار در عملکرد مدل‌های ترکیبی استفاده شده

در این مرحله از پژوهش، به منظور بررسی تأثیر تعداد نمونه‌های تصویری بیشتر از هر بیمار، مجموعه داده‌ای جدید ایجاد شد که شامل ۱۰ تصویر شبکه‌ای برای هر یک از ۱۸۸ بیمار بود. برخلاف مراحل قبلی که تنها از یک تصویر ابتدایی برای هر بیمار استفاده می‌شد، در این مرحله تلاش شد تنوع درون فردی و اطلاعات بیشتر از هر بیمار به مدل‌ها ارائه شود.

برای جلوگیری از بروز مشکل نشت داده^۱ ناشی از حضور تصاویر مربوط به یک بیمار در هر دو مجموعه آموزشی و آزمون، تقسیم‌بندی داده‌ها این بار براساس شناسه‌ی بیماران انجام گرفت. بدین ترتیب، ابتدا بیماران به سه گروه تقسیم شدند و سپس تمام تصاویر مربوط به هر بیمار تنها در یکی از گروه‌های آموزش، اعتبارسنجی یا آزمون قرار گرفتند. نسبت

^۱ Data Leakage

تقسیم بیماران به سه مجموعه به صورت ۷۰ درصد آموزش، ۱۰ درصد اعتبارسنجی، و ۲۰ درصد آزمون در نظر گرفته شد.

همانند مراحل قبلی، در این فاز نیز از چهار مدل استخراج ویژگی یادگیری عمیق پیش آموزش دیده ResNet50، VGG16، EfficientNetB0 و InceptionV3 استفاده شد. این مدل‌ها بدون هیچ گونه آموزش مجدد، صرفاً به عنوان استخراج کننده ی بردارهای ویژگی از تصاویر مورد استفاده قرار گرفتند. سپس خروجی این شبکه ها (بردارهای ویژگی) با استفاده از روش PCA به ۱۰۰ مؤلفه ی اصلی کاهش بُعد یافته و با بهره گیری از روش SMOTE مشکل عدم توازن کلاس ها در داده آموزش اصلاح شد.

در گام بعد مشابه مرحله پیشین، ویژگی های استخراج شده به شش مدل طبقه بندی که در بخش پیش ذکر شد، داده شده است. هر طبقه بند ابتدا با داده های آموزشی آموزش دیده و سپس روی مجموعه ی آزمون ارزیابی شد. معیارهای ارزیابی مشابه مراحل بودند. همچنین، زمان صرف شده برای استخراج ویژگی در این مرحله نیز ثبت گردید.

این مرحله نقش مهمی در تحلیل اثر افزایش اطلاعات درون فردی و همچنین شیوه ی مناسب تقسیم داده ها در افزایش دقت مدل ایفا می کند.

در جدول ۴ نتایج سه ترکیب برتر به ازای هر مدل استخراج ویژگی آورده شده است. همانطور که می توان دید در این مرحله ترکیب مدل های EfficientNetB0 و جنگل تصادفی بصورت معنادار، عملکرد بهتری نسبت به سایر مدل ها از دیدگاه امتیاز F1 و دقت داشته که با نتیجه مرحله قبل در مدل طبقه بندی تفاوت پیدا کرده است. همچنین از دیدگاه مساحت زیر منحنی ROC عملکرد ترکیب های ResNet50، SVM و EfficientNetB0، Random Forest قابل مقایسه و نسبت به سایر ترکیب ها عملکرد بهتری داشته اند. همچنین در جدول ۵ می توان دید مدل EfficientNetB0 همانند مرحله پیشین کمترین زمان در استخراج ویژگی را در بین ۴ مدل به خود اختصاص داده است.

جدول ۴

مدل استخراج ویژگی	مدل طبقه بندی	دقت (Accuracy)	دقت مثبت (Precision)	بازیابی (Recall)	F1- Score	مساحت زیر منحنی ROC
----------------------	---------------	-------------------	-------------------------	---------------------	--------------	------------------------

0.901	0.847	0.848	0.847	0.848	Random Forest	EfficientNetB0
0.901	0.806	0.801	0.826	0.801	SVM	ResNet50
0.876	0.807	0.809	0.806	0.809	Random Forest	VGG16
0.876	0.802	0.798	0.813	0.798	Gradient Boosting	VGG16
0.889	0.802	0.798	0.815	0.798	SVM	EfficientNetB0
0.872	0.792	0.787	0.818	0.787	Gradient Boosting	ResNet50
0.886	0.792	0.787	0.816	0.787	Logistic Regression	VGG16
0.869	0.793	0.790	0.803	0.790	XGBoost	ResNet50
0.866	0.782	0.781	0.784	0.781	XGBoost	VGG16
0.871	0.766	0.759	0.800	0.759	Logistic Regression	EfficientNetB0
0.843	0.772	0.768	0.781	0.768	SVM	VGG16

جدول ۵

مدل استخراج ویژگی	زمان استخراج ویژگی (ثانیه)
EfficientNetB0	1032.051
ResNet50	504.907

278.660	VGG16
192.480	InceptionV3

۴-۷- تحلیل اثر به کارگیری پیش پردازش تصاویر در بهبود عملکرد مدل های استفاده شده

هدف از اجرای این مرحله، ارزیابی کمی و کیفی تأثیر تقویت کیفیت بصری تصاویر شبکه بر عملکرد مدل های یادگیری ماشین در طبقه بندی بیماری ROP بوده است.

در این مرحله از پژوهش، به منظور بررسی تأثیر بهبود کیفیت تصاویر ورودی، بر عملکرد مدل های ترکیبی تشخیص بیماری ROP، از یک زنجیره ی پیش پردازش تصویر استفاده شد که به طور خاص برای تصاویر شبکه نوزادان طراحی و در مقاله ی مرجع پایگاه داده این پژوهش معرفی شده است [8] [1]. این فرآیند به صورت کد پایتون پیاده سازی شده و شامل چندین مرحله تقویتی و اصلاحی بر روی کیفیت تصاویر خام است که هدف آن ارتقاء وضوح ساختارهای بافتی مهم در شبکه و به حداقل رساندن نویز و اطلاعات غیر ضروری در تصاویر می باشد.

۱-۴-۷- مراحل پیش پردازش

پیش پردازش نهایی اعمال شده بر روی تصاویر، شامل سه مرحله اصلی زیر بوده است.

برش دایره ای ۱ و فیلتر گوسی^۲

در این گام، ابتدا نواحی تاریک حاشیه ای و بخش های فاقد اطلاعات تصویر حذف شده و سپس یک ماسک دایره ای از ناحیه مرکزی شبکه استخراج می گردد. به منظور برجسته سازی جزئیات ساختارهای مرکزی، پس از برش دایره ای، فیلتر گوسی بر روی تصویر اعمال می شود تا از تأثیر جزئیات نامربوط پیرامونی کاسته شود.

تنظیم روشنایی^۳

¹ Circle Crop


² Gaussian Filter

³ Gamma Correction

در بسیاری از تصاویر خام، به دلیل شرایط متفاوت تصویربرداری، شدت روشنایی تصویر دارای نوسانات زیادی است. در این مرحله، ابتدا میزان روشنایی میانگین تصویر با استفاده از نرم اقلیدسی کانال‌های رنگی محاسبه شده و در صورتی که از یک آستانه مشخص پایین‌تر باشد، با استفاده از تبدیل خطی، روشنایی تصویر به سطح استاندارد رسانده می‌شود.

افزایش کنتراست^۱ در کانال سبز با الگوریتم CLAHE^۲

با توجه به اینکه بیشترین اطلاعات بافتی و عروقی در تصاویر شبکه در کانال سبز نهفته است، الگوریتم CLAHE تنها بر روی این کانال اعمال گردید [1]. در این روش، هیستوگرام تصویر به صورت محلی (در بلوک‌های کوچک) هموار می‌شود تا همزمان از افزایش بیش از حد نویز جلوگیری گردد و هم کنتراست در نواحی مهم تصویر بهبود یابد. خروجی این مرحله، تصویری با وضوح بالاتر در ناحیه سبز و ساختارهای عروقی برجسته‌تر بود.



¹ Contrast

² Contrast Limited Adaptive Histogram Equalization

شکل ۴ - مراحل پیش پردازش تصویر [1]

تمام تصاویر شبکه موجود در مجموعه داده (شامل ۱۰ تصویر برای هر یک از ۱۸۸ بیمار) با استفاده از این زنجیره‌ی پیش پردازش تقویت شدند. به منظور حفظ انسجام با مراحل قبلی، تقسیم بندی داده ها همچنان بر اساس شناسه‌ی بیماران انجام گرفت؛ به این صورت که تمام تصاویر مربوط به یک بیمار فقط در یکی از مجموعه های آموزش، اعتبارسنجی یا آزمون قرار گرفتند تا از بروز پدیده‌ی نشت داده جلوگیری شود. نسبت های تقسیم نیز مشابه مرحله‌ی قبل در نظر گرفته شد.

با توجه به نتایج مرحله‌ی پیشین، در این مرحله تنها از مدل EfficientNetB0 به عنوان استخراج کننده‌ی ویژگی استفاده شد؛ چرا که این مدل در حالت بدون پیش پردازش، بالاترین عملکرد را در میان شبکه های عصبی پیش آموزش دیده نشان داده بود. بردارهای ویژگی استخراج شده از تصاویر پیش پردازش شده با استفاده از الگوریتم کاهش بُعد PCA به ۱۰۰ مؤلفه‌ی اصلی کاهش یافتند و مشکل عدم توازن کلاس ها در داده های آموزشی با استفاده از روش SMOTE برطرف گردید.

در ادامه، ویژگی های نهایی به شش طبقه بند کلاسیک معرفی شده در بخش های قبل داده شدند. مدل های مذکور پس از آموزش روی داده های آموزشی، با استفاده از مجموعه‌ی آزمون ارزیابی شدند. معیارهای ارزیابی مشابه مراحل پیشین به کار گرفته شدند.

نتایج این مرحله و مقایسه آن با نتیجه مرحله قبل براساس معیار F1-Score را برای مدل استخراج ویژگی EfficientNetB0 در ترکیب با مدل های طبقه بندی در جدول زیر می توان دید. در مجموع، نتایج این مرحله نشان می دهد که پیش پردازش تصاویر شامل برش دایره ای، تنظیم سطح روشنایی و افزایش کنتراست کانال سبز، در برخی از مدل های طبقه بندی منجر به بهبود عملکرد شده است؛ به ویژه در مدل هایی مانند KNN، SVM، Gradient Boosting و XGBoost که همگی افزایش محسوسی در معیار F1-score نسبت به مرحله قبل نشان دادند. در مقابل، برخی دیگر از مدل ها از جمله Random Forest با کاهش جزئی عملکرد مواجه شدند، که ممکن است ناشی از تغییر در توزیع آماری ویژگی ها پس از اعمال فیلترهای تصویری باشد. با این حال، باید توجه داشت که بیشینه F1-score در این مرحله ۸۵.۵۴ درصد (با مدل SVM) نسبت به مقدار بیشینه‌ی ثبت شده در مرحله‌ی قبلی ۸۴.۷۹ تنها به

میزان ۰.۷۵ درصد افزایش یافته است. بنابراین، می توان نتیجه گرفت که هرچند پیش پردازش به بهبود نسبی برخی مدل ها کمک کرده، اما در مجموع تأثیر چشمگیری بر بهبود کلی عملکرد سیستم نداشته است.

جدول ۶

تغییر	F1-Score با پیش پردازش	F1-Score بدون پیش پردازش	مدل طبقه بندی
کاهش ۴ درصدی ↓	0.807	0.847	Random Forest
افزایش ۵ درصدی ↑	0.824	0.766	Logistic Regression
افزایش ۵ درصدی ↑	0.855	0.802	SVM
افزایش ۵ درصدی ↑	0.838	0.787	XGBoost
افزایش ۸ درصدی ↑	0.740	0.652	KNN
افزایش ۸ درصدی ↑	0.837	0.752	Gradient Boosting

۵- نتایج

۵-۱- مقدمه

در این فصل، نتایج حاصل از مراحل مختلف پیاده‌سازی و ارزیابی سیستم پیشنهادی برای تشخیص بیماری رتینوپاتی نوزادان نارس ارائه و تحلیل می‌شود. هدف اصلی این فصل، بررسی عملکرد و تاثیر مدل‌های مختلف یادگیری عمیق و ترکیبی است که در سناریوهای گوناگون در فصل قبل بررسی شده است، و نتایج آنها نشان دهنده دقت و عملکرد سیستم تشخیص می‌باشد.

ساختار این فصل به صورت مرحله‌ای و بر اساس چهار بخش اصلی از فرآیند پیاده‌سازی تدوین شده است. نخست، عملکرد مدل‌های یادگیری عمیق به عنوان مدل‌های طبقه‌بندی در سناریوی تک‌تصویر مورد بررسی قرار می‌گیرد. سپس، ترکیب ویژگی‌های استخراج‌شده از شبکه‌های عمیق با طبقه‌بندهای کلاسیک و تاثیر آن بر دقت طبقه‌بندی تحلیل می‌شود. در ادامه، نتایج حاصل از تجميع چند تصویر از هر بیمار و تأثير آن بر بهبود عملکرد مدل‌ها ارائه خواهد شد. در گام چهارم، اثر اعمال پیش‌پردازش‌های تصویری مبتنی بر مطالعات گذشته بر کیفیت ویژگی‌ها و خروجی نهایی مدل بررسی می‌شود.

در انتهای فصل، با تحلیل تجميعی نتایج، مقایسه دقیق میان مدل‌ها انجام شده و با در نظر گرفتن معیارهایی مانند دقت، حساسیت، F1-Score، و هزینه محاسباتی، بهترین مدل یا مدل‌های پیشنهادی برای کاربردهای بالینی یا کمک تشخیص معرفی خواهند شد.

۲-۵- تحلیل مرحله اول: مدل‌های یادگیری مستقیم از تصویر

در نخستین مرحله از فرآیند طراحی، هدف بررسی توانایی مدل‌های یادگیری عمیق در استخراج ویژگی‌های تشخیصی به صورت مستقیم از تصاویر خام شبکیه چشم و طبقه‌بندی وجود یا عدم وجود بیماری ROP بود. در این مرحله، از چند شبکه عصبی از پیش آموزش دیده شامل DenseNet121، MobileNetV2، EfficientNetB0، ResNet50، InceptionV3 و VGG16 استفاده شد. این مدل‌ها با وزن‌های آموزش دیده بر روی مجموعه داده ImageNet بارگذاری شده و تنها لایه‌های نهایی (طبقه‌بندی) آن‌ها برای تطبیق با داده‌های جدید آموزش داده شدند. داده‌های ورودی شامل یک تصویر منتخب از هر بیمار بودند.

مقایسه نتایج این مدل‌ها که در جدول ۲ قابل مشاهده است، نشان داد که دقت کلی در طبقه‌بندی بیماری ROP محدود بوده و مقدار میانگین معیار F1 در بهترین حالت، حدود ۷۰ درصد برای مدل ResNet50 به دست آمد. سایر مدل‌ها، از جمله EfficientNetB0، VGG16 و MobileNetV2، به طور محسوسی عملکرد ضعیف‌تری داشته‌اند. این فاصله عملکرد، نشان‌دهنده آن است که مدل‌های سبک‌تر یا با عمق کمتر، در مواجهه با این نوع داده‌های چشمی که دارای پیچیدگی بصری بالایی هستند، از توانایی کافی یادگیری مؤثر در مواجهه با داده محدود، برخوردار نیستند. حجم کم داده‌های آموزشی نسبت به ظرفیت مدل‌ها که احتمال بیش‌برازش را افزایش می‌دهد از جمله چالش‌های این مرحله است. همچنین، هزینه محاسباتی بالا و زمان آموزش قابل توجه که به‌ویژه در مدل‌های پیچیده‌تر مانند InceptionV3 و DenseNet121 محسوس بود و اجرای آزمایش‌ها را زمان‌بر و منابع‌بر کرده است از معایب این روش به شمار می‌آید.

در مجموع، می‌توان چنین نتیجه گرفت که استفاده مستقیم از مدل‌های یادگیری عمیق، بدون طراحی مناسب ساختار استخراج ویژگی و با در نظر گرفتن محدودیت‌های داده و منابع پردازشی، نمی‌تواند به دقتی در سطح مورد انتظار برای کاربردهای بالینی در این پژوهش منجر شود. این مسئله، ضرورت حرکت به سوی رویکردهای ترکیبی مبتنی بر استخراج ویژگی و استفاده از طبقه‌بندهای کلاسیک را برجسته می‌سازد.

۳-۵- تحلیل مرحله دوم: استخراج ویژگی و طبقه‌بندهای کلاسیک

در گام دوم از پژوهش، تمرکز بر استفاده از شبکه‌های عصبی عمیق صرفاً به عنوان استخراج‌کننده ویژگی قرار گرفت. برخلاف مرحله نخست، این مدل‌ها وارد فرآیند یادگیری نشدند و تنها وظیفه آن‌ها تبدیل تصویر ورودی به یک بردار

ویژگی بود. سپس این بردارها به طبقه‌بندهای کلاسیک منتقل شدند تا تصمیم نهایی طبقه‌بندی بیماری (مثبت یا منفی) اتخاذ گردد. برای کاهش پیچیدگی محاسباتی و کاهش ریسک بیش‌برازش، کاهش بعد با روش PCA تا ۱۰۰ مؤلفه صورت گرفت.

همان‌طور که مشاهده می‌شود، عملکرد مربوط به ترکیب EfficientNetB0 به‌عنوان استخراج گر ویژگی با Logistic Regression به‌عنوان طبقه‌بند نهایی، نسبت به سایر ترکیب‌ها بصورت معناداری بهتر است. این ترکیب توانست به دقت حدود ۸۲ درصد، حساسیت یا بازیابی ۸۲ درصد و F1 معادل ۸۱.۸۲ درصد دست یابد، که نسبت به نتایج مرحله اول پیشرفتی چشم‌گیر به‌شمار می‌رود.

در سمت دیگر، ترکیب‌هایی که از InceptionV3 به‌عنوان استخراج گر استفاده کرده‌اند، عملکرد نسبتاً ضعیف‌تری از خود نشان دادند؛ به‌ویژه در معیار ROC-AUC که به‌شدت پایین (۴۳ تا ۶۴ درصد) گزارش شده و نشان‌دهنده ضعف مدل در تفکیک کلاس‌هاست. این در حالی است که VGG16 و ResNet50 عملکرد میانه و قابل قبولی داشتند، ولی از لحاظ عددی نتوانستند به دقت و تعادل EfficientNetB0 برسند. با این حال با مقایسه با نتایج مرحله اول پژوهش می‌توان دید که استفاده از همه این مدل‌ها به‌عنوان استخراج کننده ویژگی نتایج بسیار بهتری به نسخه طبقه‌بند آن‌ها دارد.

۴-۵- تحلیل مرحله سوم: استفاده از چند تصویر به‌ازای هر بیمار

در مرحله سوم پژوهش، هدف بررسی تأثیر افزایش تعداد تصاویر ورودی بر عملکرد مدل‌های طبقه‌بندی بود. برخلاف مراحل پیشین که تنها یک تصویر از هر بیمار مورد استفاده قرار می‌گرفت، در این مرحله از ۱۰ تصویر مختلف از هر بیمار استفاده شد. افزایش حجم داده در سطح تصویر، به‌ویژه برای داده‌های پزشکی با تنوع ساختاری بالا، می‌تواند به مدل در یادگیری الگوهای دقیق‌تر و افزایش توان تفکیک کمک کند.

فرآیند استخراج ویژگی مشابه مرحله دوم و با استفاده از شبکه‌های عصبی از پیش آموزش دیده انجام شد. بردار ویژگی حاصل از هر تصویر، پس از کاهش بُعد با روش PCA (تا ۱۰۰ مؤلفه اصلی) و اعمال تکنیک بالانس‌سازی SMOTE بر مجموعه آموزش، به مدل‌های طبقه‌بندی منتقل شد.

همان‌طور که در جدول ۵ مشاهده می‌شود، استفاده از چند تصویر به‌ازای هر بیمار منجر به افزایش قابل توجه در دقت و پایداری مدل‌ها شده است. به‌طور خاص، ترکیب EfficientNetB0 با Random Forest به بالاترین میزان دقت یعنی ۸۴.۸ درصد، بازیابی ۸۴.۸ درصد و امتیاز F1 ۸۴.۷۹ درصد، در میان مدل‌های استفاده شده در پژوهش دست یافته

است. این ترکیب همچنین از نظر مساحت زیر منحنی ROC نیز عملکردی بسیار خوب داشته و مقدار ۹۰.۱۵ درصد را ثبت کرده است.

در مقایسه عملکرد مدل‌ها در مراحل دوم و سوم پژوهش، تغییر قابل توجهی در نحوه‌ی تعامل طبقه‌بندها با ویژگی‌های استخراج‌شده از مدل EfficientNetB0 مشاهده می‌شود. در مرحله‌ی دوم، ترکیب Logistic و EfficientNetB0 Regression بهترین عملکرد را در میان سایر ترکیب‌ها به ثبت رساند و به‌عنوان گزینه‌ی برتر انتخاب شد. با این حال، در مرحله‌ی سوم که حجم داده‌ها به‌واسطه‌ی افزایش تعداد تصاویر به ازای هر بیمار افزایش یافته بود، مدل Random Forest در ترکیب با EfficientNetB0 عملکرد بهتری نسبت به Logistic Regression از خود نشان داد. در واقع، کارایی Logistic Regression نسبت به مرحله‌ی قبل با کاهش قابل ملاحظه‌ای همراه بود، به‌طوری که از جایگاه اول به یکی از ضعیف‌ترین عملکردها در میان طبقه‌بندها تنزل یافت. این تغییر می‌تواند نشان‌دهنده‌ی حساسیت Logistic Regression به ویژگی‌های تکرارشونده یا هم‌پوشان در داده‌های حجیم‌تر باشد، در حالی که مدل Random Forest به‌دلیل ساختار انعطاف‌پذیر و توانایی در یادگیری از ویژگی‌های متنوع، توانسته با افزایش داده‌ها تطابق بهتری داشته باشد. این مشاهده تأکید می‌کند که کارایی ترکیب مدل‌های یادگیری عمیق و طبقه‌بندهای کلاسیک نه تنها به معماری آن‌ها، بلکه به نحوه‌ی توزیع داده‌ها و میزان تنوع نمونه‌های آموزشی نیز وابسته است.

همچنین مشاهده می‌شود که مدل‌هایی که در مراحل قبلی عملکرد متوسطی داشتند، مانند VGG16، در این مرحله با بهره‌گیری از داده غنی‌تر، به سطح عملکرد رقابتی با مدل‌های پیشرفته‌تر رسیده‌اند. این نشان‌دهنده آن است که حجم داده بیشتر و تنوع تصویری بالاتر می‌تواند تأثیر بسزایی در بهبود توانایی مدل‌های طبقه‌بندی ایفا کند.

در مجموع، مرحله سوم پژوهش نشان داد که افزایش تعداد تصاویر به ازای هر بیمار، حتی بدون تغییر در ساختار مدل یا روش تصمیم‌گیری، می‌تواند دقت مدل را در تشخیص بیماری ROP به‌طور محسوسی ارتقاء دهد. این یافته می‌تواند در طراحی سامانه‌های غربالگری یا کمک تشخیص مبتنی بر بینایی ماشین، به‌عنوان راهبردی کارآمد مدنظر قرار گیرد.

۵-۵- تحلیل مرحله چهارم: تأثیر پیش‌پردازش تصاویر بر عملکرد مدل‌ها

در مرحله چهارم پژوهش، هدف بررسی تأثیر اعمال پیش‌پردازش‌های تصویر بر عملکرد مدل‌های یادگیری ماشین بود. بر اساس مستندات ارائه‌شده در مقاله مربوط به مجموعه داده مورد استفاده، سه مرحله پیش‌پردازش که در بخش مربوط به آن بصورت کامل بررسی شده است، بر روی تصاویر اعمال شد.

این پیش‌پردازش‌ها با هدف بهبود وضوح عروق شبکیه، حذف نورهای مزاحم و افزایش کیفیت بصری تصاویر صورت گرفت. در این مرحله، عملکرد مدل‌هایی که در مراحل قبل بر مبنای تصاویر خام آموزش دیده بودند، بار دیگر و این بار بر روی تصاویر پیش‌پردازش شده ارزیابی شد تا تأثیر این عملیات بررسی گردد.

همان‌طور که در جدول ۶ مشاهده می‌شود، اغلب مدل‌ها پس از اعمال پیش‌پردازش تصویری با افزایش قابل توجه در امتیاز F1 مواجه شدند. به‌طور خاص، مدل‌های K-Nearest Neighbors و Gradient Boosting بیشترین افزایش را تجربه کردند (به ترتیب ۸۸ و ۸۵ درصد). این موضوع نشان می‌دهد که مدل‌هایی که حساسیت بیشتری به کیفیت اولیه ویژگی‌های ورودی دارند، از بهبودهای تصویری بهره‌مند شده‌اند.

ترکیب SVM با EfficientNetB0 نیز با دستیابی به امتیاز F1 برابر با ۸۵.۵۴ درصد، به بالاترین عملکرد در میان تمام مدل‌های بررسی شده دست یافت. این بهبود نسبت به حالت بدون پیش‌پردازش با F1 معادل ۸۰.۲۵ نشان‌دهنده تأثیر مثبت افزایش وضوح ساختارهای ریز شبکیه بر دقت طبقه‌بندی مدل‌های مبتنی بر مرز تصمیم‌گیری است.

با این حال، نکته قابل توجه این است که مدل Random Forest، برخلاف سایر مدل‌ها، پس از پیش‌پردازش با افت قابل توجهی در عملکرد مواجه شد. این موضوع می‌تواند ناشی از آن باشد که در مدل‌های درختی، ویژگی‌های آماری اولیه‌ای که از داده خام استخراج شده‌اند، نقش مهم‌تری در ساخت شاخه‌های تصمیم‌گیری دارند و هرگونه تغییر در ساختار تصویری ممکن است موجب گم‌شدن برخی الگوهای مفید شود.

در مجموع، نتایج این مرحله نشان می‌دهد که پیش‌پردازش تصویری، به‌ویژه در مدل‌های حساس به کیفیت داده ورودی، نقش مهمی در بهبود عملکرد طبقه‌بندی ایفا می‌کند. هرچند تأثیر آن در تمام مدل‌ها یکسان نیست، ولی در بسیاری از موارد بهبود معناداری در خروجی حاصل شده که قابل توجه است.

۵-۶- تحلیل زمان اجرا و هزینه محاسباتی مدل‌ها

در کنار معیارهای ارزیابی عملکرد مانند دقت یا امتیاز F1، هزینه زمانی اجرای مدل‌ها نیز یکی از عوامل مهم در انتخاب مدل نهایی برای کاربردهای عملی است؛ به‌ویژه در مسائل پزشکی که ممکن است پردازش هم‌زمان تعداد زیادی تصویر در شرایط محدود منابع لازم باشد. در این بخش، زمان اجرای مدل‌ها در سه بخش اصلی مورد ارزیابی قرار گرفته است.

- زمان استخراج ویژگی توسط شبکه‌های عصبی

- عمیق زمان آموزش مدل‌های طبقه‌بندی
- زمان پیش‌بینی (تست) مدل بر روی داده‌های آزمون

بر اساس جدول ۷، ترکیب‌های برتر از مدل‌های استخراج ویژگی و طبقه‌بندها از نظر دقت نهایی و امتیاز F1 و هزینه زمانی مقایسه شده‌اند. این مقادیر در مرحله سوم تحقیق با داده شامل ۱۸۸۰ عکس بدست آمده است. نتایج نشان می‌دهد که مدل EfficientNetB0 همراه با طبقه‌بند Random Forest، با امتیاز F1 معادل ۸۴.۷۹ و مجموع زمان اجرای بسیار پایین (حدود ۱۹۵ ثانیه)، بهترین توازن میان دقت و کارایی محاسباتی را ارائه می‌دهد.

در مقابل، ترکیب‌هایی که از VGG16 به‌عنوان استخراج‌گر ویژگی استفاده کرده‌اند، اگرچه به لحاظ تشخیصی عملکرد قابل قبولی دارند، اما زمان مورد نیاز برای استخراج ویژگی در آن‌ها بیش از ۱۰۰۰ ثانیه بوده که در کاربردهای بلادرنگ یا سیستم‌های محدود از نظر منابع، می‌تواند چالش‌برانگیز باشد.

مدل ResNet50 به همراه SVM نیز عملکرد دقتی خوبی داشته (امتیاز $F1 = ۸۰.۶$ درصد)، اما با زمان استخراج بالا (۵۰۵ ثانیه) در میانه طیف زمان/دقت قرار می‌گیرد.

جدول ۷

مدل ترکیبی	F1-Score	زمان کل (ثانیه)
EfficientNetB0 + Random Forest	0.847	~195
EfficientNetB0 + SVM	0.802	~254
ResNet50 + SVM	0.806	~506
VGG16 + Gradient Boosting	0.802	~1043
InceptionV3 + Logistic Reg.	0.644	~279

~1033	0.605	VGG16 + KNN
-------	-------	-------------

۵-۷- نتیجه گیری

در نهایت، با توجه به مجموع زمان اجرا و خروجی عملکرد، می توان ترکیب EfficientNetB0 و Random Forest را به عنوان گزینه نهایی برتر از نظر دقت و سرعت از میان مدل های انتخاب شده معرفی کرد.

- [1] Juraj Timkovič *et al.*, “Retinal Image Dataset of Infants and Retinopathy of Prematurity,” *Scientific Data*, vol. 11, no. 1, Jul. 2024, doi: <https://doi.org/10.1038/s41597-024-03409-7>.
- [2] E. H. Hong, Y. U. Shin, and H. Cho, “Retinopathy of prematurity: a review of epidemiology and current treatment strategies,” *Clinical and Experimental Pediatrics*, vol. 65, no. 3, pp. 115–126, Mar. 2022, doi: <https://doi.org/10.3345/cep.2021.00773>.
- [3] Y. Tong, W. Lu, Q. Deng, C. Chen, and Y. Shen, “Automated identification of retinopathy of prematurity by image-based deep learning,” *Eye and Vision*, vol. 7, no. 1, Aug. 2020, doi: <https://doi.org/10.1186/s40662-020-00206-2>.
- [4] J. Wang *et al.*, “Automated Explainable Multidimensional Deep Learning Platform of Retinal Images for Retinopathy of Prematurity Screening,” *JAMA Network Open*, vol. 4, no. 5, p. e218758, May 2021, doi: <https://doi.org/10.1001/jamanetworkopen.2021.8758>.
- [5] N. Salih, M. Ksantini, N. Hussein, Donia Ben Halima, Ali Abdul Razzaq, and S. Ahmed, “Prediction of ROP Zones Using Deep Learning Algorithms and Voting Classifier Technique,” *International Journal of Computational Intelligence Systems*, vol. 16, no. 1, May 2023, doi: <https://doi.org/10.1007/s44196-023-00268-9>.
- [6] VM. Raja Sankari, U. Snekhalatha, A. Chandrasekaran, and P. Baskaran, “Automated diagnosis of Retinopathy of prematurity from retinal images of preterm infants using hybrid deep learning techniques,” *Biomedical Signal Processing and Control*, vol. 85, p. 104883, Aug. 2023, doi: <https://doi.org/10.1016/j.bspc.2023.104883>.
- [7] N. Salih, M. Ksantini, N. Hussein, Donia Ben Halima, Ali Abdul Razzaq, and S. Ahmed, “Prediction of ROP Zones Using Deep Learning Algorithms and Voting

Classifier Technique,” *International Journal of Computational Intelligence Systems*, vol. 16, no. 1, May 2023, doi: <https://doi.org/10.1007/s44196-023-00268-9>.

[8]“BlockedPage” *Github.com*,2025.https://github.com/JanaNowakova/Image_enhancement_retinopathy_of_prematurity (accessed Sep. 22, 2025)